

Методологический отчет СберИндекс

Команда: nomadic forecast

Содержание

1	Постановка задачи	3
2	Данные	3
3	Ограничения задачи	3
3.1	Короткая история наблюдений	3
3.2	Сложный переход между годами	4
3.3	Сезонность различается между категориями	4
3.4	Сильные различия муниципалитетов по уровню расходов	4
3.5	Отсутствие разметки шоков	4
4	Как проверяем качество модели	5
4.1	Expanding window cross-validation	5
4.2	Метрики	5
4.3	Как отличаем устойчивое улучшение от случайного	5
5	Сравнение прогнозных моделей	6
5.1	Простые прогнозы	6
5.2	Prophet	7
5.3	Классические модели временных рядов	7
5.4	Chronos-2	8
5.5	CatBoost	9
5.6	Сравнение моделей	12
5.7	Выбор итоговой модели	12
5.8	Откуда остается ошибка	13
6	Модели обнаружения точек структурных изменений и выбор лучшей	14
6.1	Методология	14
6.2	Модели	15
6.3	Сравнение моделей обнаружения структурных изменений	18
6.4	Итоговый алгоритм выявления шоков	19
6.5	Ограничения метода и результаты на 2024 год	19
7	Новости	20
7.1	Новостные признаки для прогноза	20
7.2	Что новости дали прогнозу	21
7.3	Почему новости почти не помогают прогнозу	22
7.4	Новости в детекторе шоков	22
7.5	Как согласовывать новости с данными СберИндекса	22
8	Интервалы прогноза	23
9	Прогноз на тестовой выборке (2025 год)	24

10 Приложение	24
10.1 Что проверили и не включили	24
10.2 Ограничения решения	26

1. Постановка задачи

Перед нами стояли две задачи:

1. **Прогнозирование потребления** - получить прогноз среднемесячных безналичных расходов каждого муниципального образования по каждой категории на горизонтах **1, 3, 6 и 12 месяцев**.
2. **Выявление шоков** - определить месяцы, в которых фактические расходы муниципального образования отклонились от ожидаемого уровня существенно сильнее, чем это обычно происходит для данного МО.

Таким образом, решение должно было одновременно отвечать на два вопроса: **какими будут расходы в будущем и где фактическое поведение муниципалитета стало необычным относительно его ожидаемой траектории**.

2. Данные

Для их решения использовались следующие источники:

1. **consumption.parquet** - среднемесячные безналичные расходы одного жителя муниципального образования, руб./мес., по шести категориям: «Все категории», «Продовольствие», «Здоровье», «Маркетплейсы», «Общественное питание» и «Транспорт». Период наблюдений - с января 2023 по декабрь 2024 года.
2. **market_access.parquet** - индекс доступности рынков муниципального образования, характеризующий размер рынка, до которого можно добраться.
3. **connection.parquet** - расстояния между муниципальными образованиями по автомобильным дорогам.
4. **Справочник СберИндекса** - регион, тип муниципального образования и координаты.
5. **Данные Росстата о численности населения МО**.
6. **Национальный ряд расходов СберИндекса** начиная с 2018 года - использовался как дополнительный источник информации о сезонности и общенациональной динамике.
7. **Новости российских изданий** из архива CC-News - для признаков прогноза и объяснения шоков (раздел 7).

Всего в исходных данных представлены **2190 муниципальных образований**. При этом только **2016 МО имеют полный 24-месячный ряд по всем категориям**. Именно эта выборка использовалась для проведения основных экспериментов и получения приведенных ниже результатов.

3. Ограничения задачи

Особенности исходных данных во многом определили устройство решения. По каждому муниципалитету доступно всего два года наблюдений, уровень расходов и их сезонность сильно отличаются между МО и категориями, а примеров шоков, на которых можно было бы учиться, в данных нет. Ниже разобрано, к каким решениям привело каждое из этих ограничений.

3.1. Короткая история наблюдений

Для каждого МО и каждой категории доступно **всего 24 месячных наблюдения**, а при первом прогнозе модель располагает лишь двенадцатью месяцами 2023 г. В таком ряду каждый месяц года встречается в обучении один раз, и отделить сезонность от общего тренда по отдельному муниципалитету невозможно. Поэтому мы не пытаемся выучить сезонность для каждого МО независимо, а опираемся на информацию всей панели. Там, где сезонное поведение у муниципалитетов во многом общее, строится панельный сезонный профиль, который пересчитывается в каждой точке прогноза только по доступным на этот момент данным.

3.2. Сложный переход между годами

Особенно проблемным является переход «**декабрь-январь**». При построении первого прогноза модель еще не наблюдала такой переход в обучающей выборке, хотя он является одним из наиболее выраженных регулярных изменений. Например, для категории «Все категории» январское снижение составляет около **22%**.

Чтобы не интерпретировать этот эффект как случайный шум, для категорий с общей сезонностью используется профиль, рассчитанный по всей панели. Если необходимого перехода еще нет в обучении, профиль дополнительно опирается на **национальный ряд СберИндекса за 2019-2022 годы**. При этом профиль пересчитывается в каждой точке прогнозирования и строится исключительно по информации, доступной на этот момент. Таким образом, будущие значения тестового периода не используются.

3.3. Сезонность различается между категориями

Нельзя предполагать, что один и тот же сезонный профиль одинаково хорошо описывает все категории расходов. Для «Все категории» и «Продовольствия» общая динамика месяцев объясняет значительную часть различий между муниципалитетами: по данным 2023 года соответствующий показатель составляет **76% и 83%**. Для «Маркетплейсов», «Здоровья», «Транспорта» и «Общественного питания» эта доля значительно ниже - **от 28% до 41%**. Это указывает на то, что в этих категориях сезонность сильнее зависит от конкретного МО.

Поэтому вместо единой схемы была разработана **двухвариантная модель**:

- версия **A** использует очистку ряда от общего сезонного профиля
- версия **B** не использует такую очистку

Версия для категории выбирается только по данным 2023 года, без доступа к тестовому 2024 году.

3.4. Сильные различия муниципалитетов по уровню расходов

Муниципалитеты существенно различаются по уровню расходов. Например, для категории «Общественное питание» разница между 5-м и 95-м перцентилями составляет около **20 раз**. Если прогнозировать уровень расходов напрямую, абсолютная ошибка будет определяться в основном несколькими муниципалитетами с самыми высокими расходами. Поэтому модель прогнозирует не уровень, а его изменение за месяц, в рублях или в логарифмах в зависимости от версии.

Сопоставимость приростов позволяет вместо отдельной модели для каждого МО обучать одну глобальную модель CatBoost на всех муниципалитетах категории. Такая модель видит не 12-23 наблюдения одного ряда, а десятки тысяч примеров вида «МО × месяц» и может переносить на отдельный муниципалитет закономерности, общие для всей панели.

3.5. Отсутствие разметки шоков

В данных нет ни одного месяца, про который заранее известно, был в нем шок или нет. Поэтому обучить модель отличать шоки от обычных месяцев, как в стандартной задаче классификации, невозможно, так как ей не на чем учиться.

Вместо этого мы считаем шоком месяц, в котором расходы МО сильно разошлись с тем, что от них ожидалось. Ожидаемое значение дает прогноз модели, и расхождение факта с прогнозом служит исходным сигналом. Затем этот сигнал очищается от всего, что шоком не является. Отклонение делится на обычную волатильность муниципалитета, чтобы привычные колебания нестабильных МО не принимались за шоки. Из него вычитается общее движение региона, чтобы сдвиг всего региона не давал тревогу у каждого его муниципалитета. Наконец, отклонения по шести категориям сводятся в одну оценку того, насколько необычен этот месяц для данного МО.

Шоком считаются 1% МО-месяцев с наибольшей оценкой. Поскольку настоящих размеченных шоков нет, качество метода проверяется на искусственных: в данные вносятся сдвиги известной величины, и проверяется, какую их долю метод находит.

Таким образом, при решении задачи нужно было справиться сразу с четырьмя трудностями:

- извлечь сезонность из очень короткой истории;
- учесть сильные различия между муниципалитетами и категориями расходов;
- полностью исключить попадание информации из будущего в обучение;
- находить шоки, не имея ни одного размеченного примера.

Из этих трудностей и выросла архитектура решения: одна модель, обучаемая сразу на всех муниципалитетах, выбор сезонной версии модели по обучающим данным, строгая проверка качества только на будущих месяцах и поиск шоков как отклонений от прогноза.

4. Как проверяем качество модели

4.1. Expanding window cross-validation

Для оценки качества прогнозов использовался протокол **расширяющегося окна** (expanding window cross-validation). В каждой точке старта T модель обучается на всех доступных месяцах $1, \dots, T$ и прогнозирует следующие h месяцев $T + 1, \dots, T + h$. После этого точка старта сдвигается вперед, и модель переобучается на расширившемся наборе данных. Минимальная длина обучающей выборки составляет 12 месяцев, то есть весь 2023 г.

Для всех горизонтов - **1, 3, 6 и 12 месяцев** - тестовым периодом служит 2024 г., поэтому результаты по горизонтам сравнимы между собой. Информация о будущих месяцах не используется ни при обучении, ни при построении признаков: все признаки, сезонные профили и вспомогательные показатели пересчитываются заново в каждой точке T только по данным, доступным на этот момент.

4.2. Метрики

MAE - средняя абсолютная ошибка прогноза в рублях на жителя в месяц. Это основная метрика качества внутри каждой категории, ее легко перевести в деньги.

WAPE - сумма абсолютных ошибок, деленная на сумму фактических значений, в процентах. Ею сравниваются категории с разным уровнем расходов и считается средний результат по категориям.

MAE в рублях сильнее зависит от муниципалитетов с высокими расходами на жителя, поэтому для сравнения между категориями используется WAPE. Коэффициент детерминации R^2 по уровням у любой разумной модели оказался близок к единице и практически не различал качество прогнозов, поэтому как критерий выбора модели он не использовался.

4.3. Как отличаем устойчивое улучшение от случайного

Тестовый год один, и небольшой выигрыш на нем может оказаться случайным. Поэтому изменение модели принималось только при выполнении трех условий.

Во-первых, улучшение должно быть устойчивым во времени. Новая версия должна выигрывать в большинстве точек старта и в обеих половинах 2024 г. Это особенно важно для первой половины года, когда модель впервые сталкивается с январским переходом и обучена всего на 12-17 месяцах.

Во-вторых, выигрыш должен превышать шум обучения. Одна и та же модель, обученная с другим seed (начальным значением генератора случайных чисел), дает разброс MAE около 1,6-3% для модели с сезонным профилем и до 5-12% для модели без него (src/experiments/noise.py). Поэтому близкие по качеству варианты дополнительно сравнивались на трех seed.

В-третьих, выбор модели не должен зависеть от тестового периода. Версия модели для каждой категории определяется только по обучающим данным. Отдельно проверялся выбор своей модели

для каждой пары «категория × горизонт»: модель выбиралась по январю-июню 2024 г. и оценивалась на июле-декабре (src/experiments/halves.py). Такой выбор приводил к переобучению и в итоговое решение не вошел.

Следует оговориться, что устройство двух версий модели (целевая переменная, набор признаков, сезонная поправка) сравнивалось на 2024 г. Речь идет о выборе общей конструкции модели, а не о подборе модели под каждую ячейку «категория × горизонт», но итоговая оценка качества на 2024 г. все же может быть несколько оптимистичной. Поэтому главным аргументом в пользу итоговой модели служит не одно значение ошибки, а **устойчивое превосходство на разных точках старта, горизонтах и категориях**.

5. Сравнение прогнозных моделей

После определения способа валидации следующим шагом было проверить, насколько далеко можно продвинуться от простого прогноза, не усложняя модель, и понять, какая информация действительно помогает при короткой истории наблюдений.

Сначала использовались простые наивные прогнозы, которые задали нижнюю границу сложности и позволили понять, есть ли вообще дополнительная предсказуемость сверх последнего наблюдаемого значения. Затем были проверены классические модели временных рядов и Prophet, которые строят прогноз отдельно для каждого муниципалитета. После этого была проверена предобученная фундаментальная модель Chronos-2. И наконец была построена модель CatBoost, которая обучается сразу на данных всех муниципалитетов и категорий и поэтому может использовать общие закономерности, недоступные локальным моделям.

Такой порядок позволил не только определить, как модель прогнозирования лучше, но и какой фактор дает наибольший вклад в качество прогноза - последнее значение, собственная история муниципалитета, предобученные знания модели или информация от других муниципалитетов?

5.1. Простые прогнозы

Первым этапом были проверены простые модели прогнозирования для того, чтобы установить **точку отсчета**, с которой должны сравниваться все более сложные модели. Если сложная модель не превосходит простой прогноз, ее использование в данной задаче не оправдано.

Были рассмотрены три варианта.

- 1) **Naive** - прогноз на все будущие месяцы равен последнему известному значению.
- 2) **Среднее за 3 месяца** - прогноз равен среднему значению трех последних наблюдений. Такой вариант должен быть устойчивее к случайному шуму одного месяца.
- 3) **«Как год назад × рост»** - значение того же месяца предыдущего года умножается на темп изменения последних трех месяцев относительно соответствующих месяцев прошлого года. Этот вариант предполагает, что в каждом месяце расходы ведут себя так же, как в прошлом году, только с учетом общего роста. Так мы проверяем, хватает ли одного года данных, чтобы предсказать сезонные колебания.

Результаты показали, что средний по шести категориям WAPE для Naive составил **7,9%, 9,6%, 11,5% и 12,9%** на горизонтах 1, 3, 6 и 12 месяцев соответственно. Именно эти значения используются как baseline для последующего сравнения.

На коротком горизонте наиболее полезным оказался **«как год назад × рост»**, так как его WAPE на горизонте одного месяца составил **6,4%**. Это объясняется тем, что в категориях «Все категории» и «Продовольствие» расходы почти во всех муниципалитетах меняются по месяцам одинаково, и в 2024 г. эти изменения почти точно повторили 2023 г. Поэтому прошлогоднее значение с поправкой на рост хорошо предсказывает следующий месяц.

У «Всех категорий» WAPE на 1 месяц снижается с 7,3% у Naive до 3,6%, у «Продовольствия» с 7,7% до 3,5%. У Здоровья, Общественного питания и Транспорта правило работает на уровне Naive, у

Маркетплейсов оно точнее (9,9% против 11,2%). Исключение из повторения - апрель (подраздел 5.8). Однако на горизонте 12 месяцев это правило показало худший результат - **17,1%**. Причина в том, что при наличии только одного полного года невозможно надежно оценить устойчивый годовой темп роста, ведь ошибка оценки роста затем переносится на весь год. Среднее за три месяца, напротив, сглаживает случайные месячные колебания и поэтому оказывается конкурентоспособнее Naive на горизонтах 6-12 месяцев.

Таким образом, из результатов простых моделей мы определили две особенности задачи: последнее наблюдение является сильным ориентиром, а повторяемая сезонность содержит важную информацию, но ее нельзя безоговорочно экстраполировать на год вперед.

5.2. Prophet

Следующим этапом была проверена модель **Prophet**, которую, по условиям задачи, нужно было превзойти по метрикам.

Prophet раскладывает каждый временной ряд на компоненты тренда и сезонности, а также позволяет учитывать календарные эффекты. В нашей постановке модель строится отдельно для каждого муниципалитета и каждой категории, то есть на каждой точке старта необходимо обучить $2016 \times 6 = 12\,096$ локальных моделей.

Здесь возникает принципиальное ограничение задачи: на момент первого прогноза каждый ряд содержит только 12 наблюдений, а даже на более поздних точках - не более 23. Поэтому важно было проверить, способна ли модель самостоятельно извлечь годовую сезонность из столь короткой истории.

Prophet был проверен в двух вариантах.

Вариант 1 - настройки по умолчанию. При короткой истории годовая сезонность не используется, и модель в основном продолжает оцененный тренд.

Вариант 2 - принудительная годовая сезонность. Годовая сезонность была включена вручную с порядком ряда Фурье 3 и умеренной регуляризацией. Этот вариант проверяет гипотезу о том, что даже один год наблюдений позволяет восстановить повторяющийся сезонный рисунок.

Результаты показывают, что первая гипотеза оказывается более устойчивой. Prophet по умолчанию получил **WAPE 8,5%, 9,5%, 10,2% и 13,0%** на горизонтах 1, 3, 6 и 12 месяцев. На первом горизонте он уступает Naive, поскольку при 12-23 наблюдениях локальный тренд оценивается нестабильно. На горизонте 6 месяцев сглаживание позволяет несколько улучшить результат.

Принудительное включение годовой сезонности, напротив, ухудшило прогноз: **7,9%, 11,5%, 15,8% и 24,4%**. Модель фактически вынуждена считать сезонностью все, что наблюдалось в единственном доступном 2023 году, включая случайные отклонения и разовые провалы, а затем переносит эту структуру на 2024 год.

Особенно показателен результат для категории «Все категории»: на горизонте 12 месяцев MAE варианта с принудительной сезонностью составила **9 140 руб. на жителя**, тогда как у варианта по умолчанию - **2 720 руб.**

Эксперимент с Prophet показал главную проблему задачи. В ряду одного муниципалитета каждый месяц года встречается всего один раз, поэтому модель не может понять, был ли, например, январский спад сезонным или случайным. В результате Prophet либо игнорирует сезонность, либо переносит на следующий год все колебания 2023 г., включая разовые. При этом тот же январский спад одновременно виден почти у всех муниципалитетов, и по ним вместе сезонность оценить можно. Но Prophet обучается на каждом ряду отдельно и этой информацией не пользуется.

5.3. Классические модели временных рядов

После Prophet были проверены классические методы прогнозирования - **экспоненциальное сглаживание (ETS), Theta и ARIMA**. Это было сделано для проверки, может ли более гибкое моделирова-

ние локальной динамики улучшить результат без привлечения данных других муниципалитетов.

Все три модели обучались **отдельно для каждого ряда «муниципалитет × категория»** с использованием библиотеки *statsforecast*.

ETS делает акцент на сглаживании: более свежие наблюдения получают больший вес, поэтому модель должна быть устойчивее к краткосрочному шуму.

Theta сочетает сглаженную компоненту с продолжением линейного тренда. Поэтому она проверяет гипотезу, что локальная динамика последних месяцев достаточно устойчива, чтобы ее можно было продолжить в будущее.

ARIMA моделирует зависимости между последовательными наблюдениями и ошибками. В нашем случае это позволяет проверить, есть ли в короткой истории каждого муниципалитета достаточно устойчивой автокорреляционной структуры для построения прогноза.

Параметры классических моделей выбирались автоматически по информационному критерию. Годовая сезонность с периодом 12 месяцев намеренно не включалась: при наличии всего 12-23 наблюдений отдельного муниципалитета невозможно надежно отделить один годовой цикл от тренда и случайных колебаний.

Результаты показали, что ни один из этих подходов принципиально не решает проблему короткой истории.

Для ETS средний WAPE составил **8,0%, 9,4%, 11,0% и 12,7%** на горизонтах 1, 3, 6 и 12 месяцев. Таким образом, модель лишь немного улучшает сглаженный наивный прогноз.

Theta показала **7,7%, 9,2%, 11,3% и 14,6%**. На горизонте одного месяца это лучший результат среди рассмотренных моделей, работающих исключительно с отдельным рядом муниципалитета. Однако на длинных горизонтах продолжение локального тренда приводит к накоплению ошибки.

ARIMA получила **8,1%, 10,4%, 14,2% и 20,8%**. Особенно заметно ухудшение на длинных горизонтах: при короткой истории случайные колебания могут быть приняты моделью за устойчивую динамику, после чего ошибочная динамика накапливается при прогнозировании.

Классические модели подтвердили исходную гипотезу: **проблема заключается не столько в выборе конкретного алгоритма, сколько в недостатке информации внутри отдельного муниципального ряда**. Локальная модель видит только 12-23 наблюдения и не может использовать тот факт, что аналогичные сезонные и экономические движения одновременно происходят в других муниципалитетах.

5.4. Chronos-2

Следующим вопросом было, можно ли компенсировать короткую историю за счет **предобученной модели временных рядов**. Для этого была использована модель **Chronos-2** - модель, предварительно обученная на большом наборе временных рядов из различных предметных областей. В отличие от классических моделей, Chronos-2 не обучалась специально на муниципальных рядах и использовалась в режиме прогнозирования по доступной истории.

Были проверены два варианта входных данных.

В первом случае модель получала только историю расходов конкретного муниципалитета и категории. Это позволяет проверить, насколько предобученных знаний достаточно для прогноза при коротком локальном ряде.

Во втором случае к локальной истории добавлялся **национальный ряд расходов СберИндекса с 2018 года**. Его задача - предоставить модели несколько годовых циклов и тем самым проверить гипотезу, что длинная национальная история может компенсировать отсутствие нескольких лет наблюдений на уровне отдельного муниципалитета.

Chronos-2 с локальной историей показала WAPE **7,9%, 9,6%, 12,1% и 15,9%** на горизонтах 1, 3, 6 и 12 месяцев. Добавление национального ряда дало **7,7%, 9,4%, 12,1% и 16,2%** соответственно.

Таким образом, национальная история действительно дает небольшой выигрыш на горизонтах 1-3 ме-

сяца, однако не улучшает прогноз на 6 месяцев и ухудшает результат на 12 месяцев. В целом Chronos-2 остается примерно на уровне простых базовых моделей на коротком горизонте и уступает им на длинном.

Можно сделать вывод, что само по себе наличие более мощной предобученной архитектуры не решает проблему короткой муниципальной истории. Для существенного улучшения прогноза необходимо дать модели информацию, которой нет в отдельном ряде. В нашей задаче таким источником информации становятся другие муниципалитеты.

5.5. CatBoost

Исходя из результатов вышеупомянутых моделей, можно сделать вывод, что локальные модели ограничены короткой историей каждого муниципалитета, поэтому следующий шаг - **обучить одну глобальную модель сразу на всех муниципалитетах**.

Для этого наблюдения всех МО объединяются в одну обучающую выборку. Каждая ее строка описывает конкретный муниципалитет в месяц t , а целевая переменная показывает, как изменятся его расходы в следующем месяце. Своя модель строится для каждой категории расходов, но внутри категории она обучается сразу на всех 2016 муниципалитетах. В результате вместо 12-23 наблюдений одного ряда модель получает 20-40 тыс. строк. Индивидуальные особенности МО при этом не теряются, потому что модель видит его собственную историю и характеристики.

Обучение на всей панели позволяет модели находить закономерности, которые невозможно оценить по одному ряду. Она видит общие для всех МО изменения расходов и повторяющиеся сезонные движения. Кроме того, ей доступны различия между регионами, сходство соседних муниципалитетов и связь динамики с уровнем расходов, размером населения и доступностью рынка. Признаки при этом строятся только по данным, известным до момента прогноза, поэтому информация из будущего в модель не попадает.

В качестве модели выбран градиентный бустинг CatBoost. Он хорошо работает с табличными данными, напрямую принимает категориальные признаки, такие как регион, тип МО и месяц года, и сам находит нелинейные зависимости между динамикой расходов, характеристиками муниципалитета и движением всей панели.

Для этой модели мы проверили две версии, которые по-разному работают с сезонностью и целевой переменной. Их сравнение показало, в каких категориях общая сезонность панели действительно помогает прогнозу, а в каких мешает.

Целевая переменная и рекурсивный прогноз

Модель предсказывает не уровень расходов, а их прирост за месяц. В зависимости от версии это прирост в рублях ($y_t - y_{t-1}$) или в логарифмах ($\log y_t - \log y_{t-1}$), то есть фактически в процентах. Прирост сопоставим у муниципалитетов с разным уровнем расходов, поэтому одна модель может обучаться сразу на всей панели, не подстраиваясь под самые «богатые» МО.

Прогноз на несколько месяцев вперед строится рекурсивно: предсказанное значение на месяц $T + 1$ подставляется в историю как факт, после чего шаг повторяется для следующего месяца. Чтобы ошибка не накапливалась от шага к шагу, предсказанный прирост ограничивается 0,5%- и 99,5%-ными квантилями приростов обучающей выборки. В модели используется 500 деревьев глубины 6 со скоростью обучения 0,05 и функцией потерь RMSE; подбор глубины, регуляризации и числа деревьев менял MAE лишь в пределах шума обучения.

Признаки

Все признаки для месяца t считаются только по предыдущим месяцам (src/models/global_ml.py), поэтому информация из будущего в модель не попадает. Признаки описывают недавнюю динамику

и уровень расходов МО, его сезонность, а также поведение всей панели, своего региона и соседей (таблица 1).

Таблица 1. Признаки глобальной модели

Группа	Признаки
Недавняя динамика	приросты за 1, 2 и 3 последних месяца, в рублях и в логарифмах
Уровень	последнее значение (в рублях и в логарифмах), средний уровень расходов МО
Отклонение и шум	отклонение последнего значения от среднего за 3 и 6 месяцев; разброс месячных приростов за 6 месяцев
Сезонность	месяц года (категориальный); прирост того же месяца год назад; отношение уровня год назад к последнему значению; рост год к году
Общая динамика	медиана приростов всех МО за прошлый месяц и за тот же месяц год назад
Статика МО	индекс доступности рынков
Справочник МО*	регион, тип МО, административный центр, ЗАТО (категориальные); координаты
Регион и соседи*	медианный прирост МО своего региона (за месяц, год назад, год к году); средний прирост пяти ближайших по дороге МО
Население*	численность населения и ее прирост за 2022 г.

* используются только в версии А.

Сезонный профиль панели

По одному году данных модель не может выучить сезонность, потому что каждый месяц года встречается в обучении только один раз. Поэтому в категориях, где сезонность у всех МО общая, мы убираем ее заранее с помощью сезонного профиля, то есть типичного прироста расходов в каждом месяце года.

Профиль для месяца равен медиане логарифмического прироста по всем МО в этот месяц, усредненной по годам обучения, за вычетом среднего месячного тренда. Он пересчитывается в каждой точке старта. Ряды делятся на профиль, модель прогнозирует очищенный ряд, а затем прогноз умножается на профиль обратно. Если какого-то месяца в обучении еще нет (январь при обучении только на 2023 г.), его значение берется из национального профиля СберИндекса за 2019-2022 гг.

Чтобы профиль действительно работал, потребовались два уточнения. Во-первых, обучение должно начинаться с февраля. Можно начинать с марта, чтобы для каждого месяца был известен прирост за прошлый месяц, но тогда февраль выпадает из обучения. В очищенном ряду февраль стабильно на 6-10% выше профиля, и модель, не видевшая этого, занижает весь прогноз начиная с февраля. Недостающие для февраля признаки просто остаются пустыми.

Во-вторых, профиль нужно строить по самим муниципальным данным, а не по национальному ряду. Национальный профиль плохо с ними согласуется. У Здоровья и Общепита после очистки национальным профилем в январе оставалось +19...+23%.

Две версии модели и правило выбора

Профиль по панели заметно улучшает прогноз «Всех категорий» и Продовольствия, но ухудшает Здоровье и Общепит. В этих категориях у каждого МО своя сезонность, и общий профиль ее искажает. Кроме того, январь при первом прогнозе берется из национального профиля, где новогодний спад по этим категориям на 18-25 п.п. глубже, чем в муниципальных данных, а по одному 2023 г. этого не узнать. Поэтому мы используем две версии модели и для каждой категории выбираем версию по обучающим данным.

Таблица 2. Устройство двух версий модели

	Версия А	Версия Б
Целевая переменная	прирост в логарифмах	прирост в рублях
Сезонность	ряд очищен профилем по панели	через признаки месяца и прошлого года
Признаки	все признаки из таблицы 1	без признаков, отмеченных звездочкой
Первая цель обучения	февраль	март (нужен прирост за прошлый месяц)

Обе версии представляют собой CatBoost с одинаковыми гиперпараметрами, и их устройство также проверялось экспериментально. Для четырех категорий версии Б справочник МО, регион, соседи и население снижают MAE на горизонте 1 месяц на 0-7%, но повышают ее на горизонте 6 месяцев на 2-8%, поэтому в версию Б они не вошли. Целевая переменная выбрана аналогично. В версии А прирост в рублях вместо логарифмов повышает MAE на 1-13% на горизонтах 1-6 месяцев, а в версии Б прирост в логарифмах вместо рублей повышает MAE на 1-46%, за единственным исключением Общепита на 12 месяцев.

Версия выбирается по тому, насколько сезонность категории общая для всех МО. По первым 12 месяцам считается доля разброса месячных приростов, которую объясняет общий для всех МО прирост этого месяца (коэффициент детерминации общего месяца):

$$R^2 = 1 - \frac{\text{Var}(d - \text{med}_{\text{месяц}}(d))}{\text{Var}(d)},$$

где d - месячные логарифмические приросты по всем МО и месяцам, а $\text{med}_{\text{месяц}}(d)$ - медиана приростов по МО в соответствующем месяце. Если $R^2 \geq 0,5$, сезонность считается общей и используется версия А, иначе версия Б (src/forecast/final.py).

Таблица 3. Доля общего месяца в разбросе приростов и выбранная версия модели

Категория	R^2 общего месяца, 2023 г.	Версия модели
Продовольствие	0,83	А
Все категории	0,76	А
Маркетплейсы	0,41	Б
Здоровье	0,37	Б
Транспорт	0,29	Б
Общественное питание	0,28	Б

Между двумя группами категорий лежит разрыв от 0,41 до 0,76, поэтому точное значение порога на выбор не влияет.

Правило ошибается только для Транспорта. На тестовом периоде профиль снижает его MAE на 10-25%, но по данным 2023 г. Транспорт неотличим от Общепита (R^2 0,29 и 0,28), которому профиль вредит. Подгонять правило под тест мы не стали.

Результаты

Версия Б во всех категориях дает WAPE 6,3%, 7,9%, 9,2% и 11,6% на горизонтах 1, 3, 6 и 12 месяцев. Это уже точнее всех моделей, обучаемых на одном ряду, на каждом горизонте. Версия А во всех категориях лучше на горизонте 1 месяц (5,2%), но на 12 месяцев ее ошибка растет до 16,9%, потому что в категориях с разной сезонностью общий профиль вредит. Итоговая модель, в которой версия выбирается по правилу, берет лучшее от обеих и дает **5,3%, 6,5%, 7,5% и 9,9%**.

Таким образом, глобальная модель снимает главное ограничение локальных моделей, потому что учится на всех муниципалитетах сразу, а сезонную поправку применяет только там, где сезонность действительно общая.

5.6. Сравнение моделей

В таблице ниже собраны результаты всех моделей. Модели, которые обучаются на одном ряду (Prophet, ETS, Theta, ARIMA, Chronos-2), почти не выигрывают у простых прогнозов, а на длинных горизонтах часто им проигрывают. Заметное улучшение появляется только при переходе к одной модели на все муниципалитеты. Линейная регрессия Ridge на тех же признаках точнее простых прогнозов на горизонтах 1-6 месяцев, но CatBoost точнее нее, так что важны не только признаки, но и сама модель. Лучший результат дает итоговая модель, которая выбирает для каждой категории одну из двух версий CatBoost, и только она точнее Prophet во всех 24 сочетаниях «категория × горизонт».

Таблица 4. Итоговое сравнение моделей прогнозирования, WAPE

Модель	Тип модели	1 мес.	3 мес.	6 мес.	12 мес.	Точнее Prophet, из 24
«Как в прошлом месяце» (Naive)	простая	7,9%	9,6%	11,5%	12,9%	12 из 24
Среднее за 3 месяца	простая	8,3%	9,9%	9,8%	12,0%	15 из 24
«Как год назад × рост»	простая	6,4%	9,2%	12,9%	17,1%	14 из 24
Prophet, настройки по умолчанию	отдельная модель на МО	8,5%	9,5%	10,2%	13,0%	-
Prophet с годовой сезонностью	отдельная модель на МО	7,9%	11,5%	15,8%	24,4%	10 из 24
ETS	отдельная модель на МО	8,0%	9,4%	11,0%	12,7%	11 из 24
Theta	отдельная модель на МО	7,7%	9,2%	11,3%	14,6%	11 из 24
ARIMA	отдельная модель на МО	8,1%	10,4%	14,2%	20,8%	9 из 24
Chronos-2	предобученная	7,9%	9,6%	12,1%	15,9%	9 из 24
Chronos-2 + национальный ряд	предобученная	7,7%	9,4%	12,1%	16,2%	9 из 24
Ridge-регрессия на признаках	глобальная	7,4%	7,9%	9,9%	15,7%	16 из 24
CatBoost, версия А	глобальная	5,2%	7,9%	11,1%	16,9%	16 из 24
CatBoost, версия Б	глобальная	6,3%	7,9%	9,2%	11,6%	18 из 24
CatBoost, итоговая модель (А/Б)	глобальная	5,3%	6,5%	7,5%	9,9%	24 из 24

Примечание. WAPE усреднен по шести категориям. В последнем столбце указано, в скольких из 24 сочетаний «категория × горизонт» модель имеет меньшую MAE, чем Prophet по умолчанию.

При этом преимущество финальной модели сохраняется не только в относительных метриках WAPE, но и в абсолютной ошибке MAE, что особенно важно для интерпретации практического эффекта: например, для категории «Все категории» ошибка прогноза на горизонте 12 месяцев снижается с 2 720 до 2 038 руб. на жителя в месяц.

5.7. Выбор итоговой модели

Итоговой выбрана глобальная модель CatBoost, версия которой для каждой категории определяется по данным 2023 г. У нее самая низкая средняя ошибка на всех четырех горизонтах, и она превосходит Prophet во всех 24 сочетаниях «категория × горизонт» (таблица 5) - на 25-66% по «Всем категориям» и Продовольствию и на 26-50% по Здоровью, Общепиту и Транспорту. Преимущество сохраняется и в абсолютной ошибке. Например, для «Всех категорий» на горизонте 12 месяцев MAE снижается с 2 720 до 2 038 руб. на жителя в месяц.

У Маркетплейсов отрыв скромнее - 7-12% на горизонтах 1-6 месяцев, а на 12 месяцев модели идут вровень (956 и 957 руб.). Это слабое место решения. На годовом горизонте для Маркетплейсов точнее оказывается простое среднее за 3 месяца (795 руб.), однако этот горизонт оценен лишь по одной точке старта, и менять модель ради него мы не стали.

Таблица 5. Итоговая модель против Prophet: MAE, руб. на жителя в месяц (итоговая / Prophet, в скобках - изменение)

Категория	1 мес.	3 мес.	6 мес.	12 мес.
Все категории	810 / 1 805 (-55%)	1 014 / 1 882 (-46%)	1 383 / 2 136 (-35%)	2 038 / 2 720 (-25%)
Продовольствие	294 / 871 (-66%)	413 / 887 (-53%)	602 / 918 (-34%)	743 / 1 086 (-32%)
Здоровье	87 / 119 (-27%)	86 / 132 (-35%)	94 / 134 (-30%)	119 / 180 (-34%)
Маркетплейсы	477 / 511 (-7%)	561 / 600 (-7%)	620 / 708 (-12%)	956 / 957 (0%)
Общественное питание	70 / 142 (-50%)	90 / 157 (-43%)	109 / 152 (-28%)	120 / 182 (-34%)
Транспорт	95 / 149 (-36%)	130 / 175 (-26%)	130 / 192 (-32%)	159 / 241 (-34%)

Абсолютная точность итоговой модели по категориям приведена в таблице 6. Самая высокая относительная ошибка у Маркетплейсов, самая низкая - у «Всех категорий» и Продовольствия.

Таблица 6. MAE итоговой модели по категориям, руб. на жителя в месяц (в скобках - WAPE)

Категория	1 мес.	3 мес.	6 мес.	12 мес.
Все категории	810 (2,6%)	1 014 (3,3%)	1 383 (4,5%)	2 038 (6,7%)
Продовольствие	294 (2,3%)	413 (3,3%)	602 (4,8%)	743 (5,9%)
Маркетплейсы	477 (10,1%)	561 (11,9%)	620 (13,1%)	956 (20,2%)
Транспорт	95 (5,3%)	130 (7,3%)	130 (7,3%)	159 (8,9%)
Здоровье	87 (5,9%)	86 (5,9%)	94 (6,3%)	119 (8,0%)
Общественное питание	70 (5,6%)	90 (7,2%)	109 (8,7%)	120 (9,6%)

5.8. Откуда остается ошибка

Чтобы понять, где лежит оставшийся резерв точности, ошибка итоговой модели была разложена на три части - общий для всех МО промах месяца, промах своего региона и остаток, относящийся к самому муниципалитету. Если бы общий промах месяца был известен заранее, MAE на горизонте 1 месяц оказалась бы ниже на 16-53% в зависимости от категории, а при известном промахе региона - на 28-63%. Иначе говоря, от трети до половины ошибки приходится на общее движение месяца.

Этот общий промах сосредоточен в январе, феврале и апреле 2024 г. В январе модель впервые сталкивается с переходом «декабрь-январь», которого не было в обучении. В апреле она переносит на 2024 г. провал апреля 2023 г., когда муниципальные расходы оказались на 7% ниже мартовских (при -0,3% по национальному ряду), хотя в 2024 г. этот провал не повторился. Остаток МО, напротив, от месяца к месяцу не сохраняется (его автокорреляция близка к нулю), так что предсказать его нечем.

Шоки вносят в ошибку сравнительно небольшой вклад. Месяцы, отмеченные как шоки, дают 1-2% суммарной ошибки, а муниципалитеты, у которых шок случился до точки старта (12% строк), - 13-18%. Их MAE в 1,3-1,6 раза выше обычной, но прогноз для них почти не смещен (подраздел 6.5). Даже идеальная обработка шоков сняла бы не более 4-6% ошибки.

Таким образом, основной резерв точности связан с общим для всех МО движением в тех месяцах, которых модель еще не видела. Он исчезает сам по мере роста истории - в прогнозе на 2025 г. январь уже присутствует в обучении.

6. Модели обнаружения точек структурных изменений и выбор лучшей

6.1. Методология

Для решения второй задачи мы сначала определили, что считать шоком. Шок, или точка структурного изменения, - это месяц, в котором фактические расходы муниципалитета существенно отклонились от ожидаемого уровня. Иначе говоря, поведение МО изменилось сильнее, чем позволяли ожидать его обычная динамика, общая динамика страны и региона и движение остальных категорий расходов. Причины такого изменения бывают самыми разными - от закрытия крупного предприятия или паводка до открытия торгового центра.

Поскольку сигнал о шоке нужен в тот же месяц, когда поступают данные, все рассмотренные методы работают в реальном времени: оценка за месяц t строится только по данным до t включительно.

В итоговом решении точка структурного изменения определяется относительно прогноза:

$$d_{i,c,t} = \log \frac{y_{i,c,t}}{\hat{y}_{i,c,t}},$$

где i - муниципалитет, c - категория расходов, t - месяц, $y_{i,c,t}$ - фактические расходы, а $\hat{y}_{i,c,t}$ - прогноз итоговой модели на один месяц, построенный только по информации, доступной до месяца t . Положительное значение $d_{i,c,t}$ означает, что расходы оказались выше ожидаемых, отрицательное - ниже. Такой подход позволяет искать не абсолютные аномалии, а отклонения от ожидаемого поведения конкретного муниципалитета.

Однако само по себе отклонение от прогноза еще не свидетельствует о шоке. У такого подхода есть три ограничения.

- 1) Одинаковое процентное отклонение имеет разную значимость для стабильного и для волатильного муниципалитета. Отклонение на 10% для стабильного МО может быть необычным, а для нестабильного - обычным колебанием.
- 2) Если в каком-то месяце модель недооценила расходы по всей стране или региону, одинаковое отклонение у сотен МО не означает, что в каждом из них произошел отдельный шок.
- 3) Структурное изменение может проявиться одновременно в нескольких категориях, и такой сигнал сильнее, чем отклонение только в одной. Особенно показательна смена структуры трат, когда одни категории растут, а другие падают.

Исходя из этого, мы последовательно проверили несколько методов - от простого скачка расходов до многомерной робастной оценки.

Так как в данных нет ни одного размеченного шока, качество методов проверялось на искусственных шоках известной величины (src/shocks/benchmark.py). В 400 случайно выбранных МО-месяцах 2024 г. (январь-октябрь) расходы МО начиная с этого месяца и до конца ряда умножались на постоянный множитель, что моделирует устойчивый сдвиг уровня. Использовались три формы шока величиной $x = 5, 10, 20$ и 30%:

- **общий** - все шесть категорий падают на x ;
- **одна категория** - падает одна случайно выбранная категория;
- **«ЧС»** - меняется структура трат: продовольствие растет на $\frac{x}{2}$, маркетплейсы и общепит падают на x , транспорт на $\frac{x}{2}$, а «Все категории» на $\frac{x}{3}$.

Порог каждого метода подбирался так, чтобы среди МО-месяцев без вставок доля ложных тревог составляла 1%. Главной метрикой служила полнота - доля найденных вставок в месяц шока, а также не позже, чем через один и два месяца. Поскольку все методы получают одни и те же вставки при одинаковой доле ложных тревог, их полнота сравнима напрямую.

6.2. Модели

Мы сравнили пять подходов в порядке усложнения. Первые три строят «норму» без прогнозной модели, последние два - от прогноза. Каждый следующий подход устраняет главный недостаток предыдущего.

1) Скачок к прошлому месяцу

В самом простом варианте шоком считается необычно большой прирост расходов за месяц:

$$g_{i,c,t} = \log y_{i,c,t} - \log y_{i,c,t-1}, \quad z_{i,c,t} = \frac{g_{i,c,t} - \text{med}_G g}{s_G},$$

где G - группа «категория $\times$ месяц $\times$ уровень расходов МО», а s_G - робастный разброс приростов в группе. Шесть категорий сводятся в одну оценку среднеквадратичным по трем наибольшим отклонениям.

Этот метод находит лишь 10,5% шоков величиной 10%, а падение одной категории почти не замечает (1,6%). Причина в том, что в одни и те же месяцы все МО меняются на 10-20% по сезонным причинам и шок теряется на этом фоне. Значит, сезонность необходимо убирать.

2) Отклонение от своего региона (peer)

Во втором подходе сезонность убирается сравнением с соседями. Из прироста МО вычитается медианный прирост МО того же региона $R(i)$, и результат делится на обычный разброс таких отклонений у данного МО:

$$e_{i,c,t} = g_{i,c,t} - \text{med}_{j \in R(i)} g_{j,c,t}, \quad z_{i,c,t} = \frac{e_{i,c,t}}{\hat{\sigma}_{i,c}(e)}.$$

Полнота вырастает до 38,2% при шоке 10% и 74,3% при шоке 20%. Однако метод не видит шок, если сдвинулся весь регион, и путает собственную сезонность МО с шоком.

3) Классические методы точки изменения

Были проверены два варианта. В первом отклонение уровня МО от медианы региона сравнивается с его средним за шесть прошлых месяцев:

$$\ell_{i,c,t} = \log y_{i,c,t} - \text{med}_{j \in R(i)} \log y_{j,c,t}, \quad u_{i,c,t} = \ell_{i,c,t} - \frac{1}{6} \sum_{k=1}^6 \ell_{i,c,t-k}.$$

Во втором к тому же отклонению применяется двусторонний CUSUM (cumulative sum), который накапливает небольшие отклонения одного знака, пока сумма не превысит порог:

$$S_t^+ = \max(0, S_{t-1}^+ + u_t - k), \quad S_t^- = \max(0, S_{t-1}^- - u_t - k).$$

Результат оказался слабым - 22,6% и 3,3% при шоке 10%. Без ограничения памяти CUSUM почти ничего не находит (0,4%). У многих МО безналичные расходы плавно растут относительно региона, сумма копится и без шока, и порог при 1% ложных тревог становится недостижимым. Ограничение памяти тремя месяцами ситуацию не исправляет. Классические методы рассчитаны на стационарный ряд, а наши ряды растут, поэтому им нужна хорошая модель «нормы».

4) Отклонение от прогноза, нормированное на волатильность МО

В качестве «нормы» берется прогноз итоговой модели (раздел 5), который уже учитывает сезонность МО, динамику региона и соседей. Чтобы учесть первое ограничение из подраздела 6.1, отклонение $d_{i,c,t}$ нормируется на обычный разброс отклонений этого МО:

$$\tilde{d}_{i,c,t} = \frac{d_{i,c,t}}{\hat{\sigma}_{i,c}(d)}.$$

После этого большой остаток перестает автоматически считаться шоком, если подобные отклонения регулярно случаются в данном муниципалитете.

Полнота составила 36,6% при шоке 10% и 75,2% при 20%, на уровне реет-подхода. Прогноз оказался удачной «нормой», но второе и третье ограничения остаются. Метод не отличает общий промах прогноза и шок региона от шока МО и не замечает необычной структуры трат.

5) Отклонение от прогноза с разложением «страна / регион / МО»

Отклонение фактических расходов от прогноза складывается из нескольких составляющих, и шоком муниципалитета является лишь одна из них. Модель могла ошибиться для всей страны сразу - например, в 2024 г. она впервые видит январь и недооценивает новогодний провал у всех МО одновременно. Сдвинуться может и весь регион из-за погоды, местной сезонности или события регионального масштаба. Расходы малых муниципалитетов, кроме того, колеблются сильнее, и заметное отклонение для них - обычное дело. И только оставшаяся часть отражает то, что действительно произошло именно в этом МО.

Четвертый подход смешивает все эти составляющие в одной оценке, из-за чего общий промах прогноза оборачивается сотнями одновременных тревог, сдвиг региона дает сигнал почти у каждого его МО, а «шумные» муниципалитеты попадают под подозрение чуть ли не каждый месяц. Поэтому в итоговом методе мы шаг за шагом вычитаем из отклонения все, что объясняется общими причинами, и ищем шок только в том, что осталось. Для этого последовательно проверяется, выделяется ли отклонение на фоне сопоставимых МО по стране, выделяется ли оно на фоне своего региона и насколько оно необычно для самого муниципалитета с учетом его истории.

Поясним логику на условном примере. Допустим, в каком-то месяце модель недооценила общепит по стране в целом на 5%, весь регион дополнительно просел на 3%, а в конкретном МО расходы на общепит упали на 20% относительно прогноза. Тогда из 20% отклонения 5 п.п. приходятся на общий промах прогноза, 3 п.п. - на регион, и лишь оставшиеся около 12 п.п. характеризуют сам муниципалитет. Именно эту часть и следует сравнивать с его обычной волатильностью.

Шаг 1. Удаление общей составляющей. Из отклонения МО вычитается медиана по сопоставимым муниципалитетам, и результат нормируется на разброс в группе и на волатильность самого МО:

$$z_{i,c,t} = \frac{d_{i,c,t} - \text{med}_{j \in G} d_{j,c,t}}{s_G \cdot \hat{\sigma}_{i,c}},$$

где G - группа «категория $\times$ месяц $\times$ уровень расходов МО», $\text{med}_{j \in G} d_{j,c,t}$ - типичное отклонение в группе, то есть общий промах прогноза в этом месяце, s_G - робастный разброс отклонений внутри группы, а $\hat{\sigma}_{i,c}$ - собственная волатильность МО по прошлым месяцам. Медиана используется вместо среднего потому, что она устойчива к выбросам и несколько муниципалитетов с настоящими шоками не сдвигают оценку общей составляющей. Группировка по уровню расходов нужна потому, что у МО с низкими расходами на жителя ошибки прогноза систематически больше и сравнивать их следует с похожими МО, а не со всей страной. После этого шага общий промах прогноза больше не превращается в сотни ложных тревог.

Шаг 2. Разделение «регион / МО». На следующем уровне так же выделяется региональная составляющая. Медиана нормированных отклонений по МО региона дает региональную составляющую, а остаток - местную:

$$r_{R,c,t} = \text{med}_{j \in R} z_{j,c,t}, \quad \lambda_{i,c,t} = z_{i,c,t} - r_{R(i),c,t}.$$

Региональная часть $r_{R,c,t}$ используется для поиска шоков всего региона, местная часть $\lambda_{i,c,t}$ - для шоков МО. Благодаря такому разделению сдвиг всего региона дает один региональный сигнал, а не тревоги у большинства его муниципалитетов.

Шаг 3. Поправка на хроническую нестабильность. Даже после вычитания общей и региональной составляющих муниципалитеты различаются тем, насколько сильно обычно колеблется их местная часть. Поэтому она еще раз нормируется на разброс прошлых местных отклонений того же МО:

$$\tilde{\lambda}_{i,c,t} = \frac{\lambda_{i,c,t}}{\hat{\sigma}_{i,c}(\lambda)}.$$

Полученная величина показывает, во сколько раз текущее местное отклонение больше привычного для этого муниципалитета. У МО с постоянно «шумными» расходами тревога не срабатывает каждый месяц, а у стабильных МО заметным становится даже умеренное, но нехарактерное отклонение.

Шаг 4. Одна оценка по шести категориям. Шесть очищенных отклонений, полученных для МО-месяца, сводятся в одну оценку, по которой принимается решение о шоке. Эта оценка должна реагировать как на общий сдвиг, когда несколько категорий одновременно отклоняются в одну сторону (например, после закрытия крупного предприятия), так и на изменение структуры трат, когда одни категории растут, а другие падают (например, при ЧС жители запасаются продуктами и перестают ходить в кафе). Вектор $\tilde{\lambda}_{i,t} = (\tilde{\lambda}_{i,1,t}, \dots, \tilde{\lambda}_{i,6,t})$ сводится в одну оценку тремя способами.

- **Top-k** - среднеквадратичное трех наибольших по модулю отклонений, хорошо ловит общий сдвиг:

$$T_{i,t} = \sqrt{\frac{1}{3} \sum_{k=1}^3 \tilde{\lambda}_{i,(k),t}^2},$$

где $\tilde{\lambda}_{i,(k),t}$ - k -е по величине модуля отклонение.

- **Робастное расстояние Махаланобиса** - показывает, насколько необычно само сочетание отклонений с учетом того, как категории обычно меняются вместе, и ловит смену структуры трат («продукты выросли, общепит упал»):

$$M_{i,t} = \sqrt{(\tilde{\lambda}_{i,t} - \hat{\mu})^\top \hat{\Sigma}^{-1} (\tilde{\lambda}_{i,t} - \hat{\mu})},$$

где $\hat{\mu}$ и $\hat{\Sigma}$ - робастные оценки центра и ковариационной матрицы (Minimum Covariance Determinant).

- **Isolation Forest** - алгоритм поиска аномалий, в котором случайные деревья быстрее изолируют необычные точки.

Оценка **combo** объединяет сильные стороны top-k и Махаланобиса. Обе оценки переводятся в проценты, и берется большая из них:

$$C_{i,t} = \max(F_T(T_{i,t}), F_M(M_{i,t})),$$

где F_T и F_M - эмпирические функции распределения соответствующих оценок по МО-месяцам. При шоке 10% полнота составила 43,9% для top-k, 45,5% для расстояния Махаланобиса, 40,2% для Isolation Forest и 47,2% для combo.

6.3. Сравнение моделей обнаружения структурных изменений

Таблица 7. Доля найденных шоков в месяц шока при 1% ложных тревог, %

Метод	Шок 5%	Шок 10%	Шок 20%	Шок 30%
1. Скачок к прошлому месяцу	1,0	10,5	40,0	53,8
2. Отклонение от региона (peer)	12,5	38,2	74,3	87,6
3а. Уровень к среднему за 6 мес.	4,2	22,6	62,3	80,9
3б. CUSUM по уровню	0,8	3,3	20,6	35,6
4. Отклонение от прогноза	10,6	36,6	75,2	88,2
5. Разложение, top-k	14,0	43,9	80,3	89,8
5. Разложение, Махаланобис	13,4	45,5	83,6	91,2
5. Разложение, Isolation Forest	14,7	40,2	76,5	88,2
5. Разложение, combo (выбран)	14,8	47,2	83,1	91,0

Примечание. Значения усреднены по трем формам шока.

Таблица 8. Доля найденных шоков по формам шока, шок 10%, месяц шока, %

Метод	Все категории	Одна категория	«ЧС»
1. Скачок к прошлому месяцу	27,8	1,6	2,0
2. Отклонение от региона (peer)	70,5	19,5	24,6
3а. Уровень к среднему за 6 мес.	43,0	10,4	14,5
3б. CUSUM по уровню	7,2	1,6	1,1
4. Отклонение от прогноза	71,3	15,9	22,6
5. Разложение, top-k	79,9	23,1	28,8
5. Разложение, Махаланобис	68,0	29,4	39,1
5. Разложение, combo (выбран)	77,4	28,8	35,5

Примечание. Top-k сильнее на общем падении, расстояние Махаланобиса - на изменении структуры трат. Combo почти не уступает лучшему из них в каждой форме шока, поэтому в среднем оказывается первым.

Если дать методам один-два месяца после шока, результаты почти не меняются: у combo при шоке 10% полнота растет лишь с 47,2% до 48,4%, поскольку сдвиг уровня замечен уже в первый месяц, а затем становится новой нормой, от которой строится следующий прогноз. Исключение составляет CUSUM, который по своей конструкции накапливает сигнал постепенно и за два месяца поднимает полноту с 3,3% до 21,2%, однако даже с этой отсрочкой заметно уступает тому, что combo находит в сам месяц шока.

Шок всего региона способен распознать только метод 5 с разложением, поскольку лишь в нем региональная составляющая оценивается отдельно. Падение всего региона на 5% обнаруживается в 75% случаев, а на 10% и более - во всех случаях при 2% ложных тревог среди регион-месяцев. Без такого разложения региональный шок величиной -10% вызвал бы тревогу у 64% муниципалитетов региона, хотя в действительности за ними стоит одно событие регионального масштаба.

В качестве итогового выбран метод с разложением «страна / регион / МО» и оценкой combo (src/shocks/detector.py), который находит больше всего шоков величиной 5-10% и не уступает расстоянию Махаланобиса на шоках 20-30%. Он одинаково хорошо реагирует как на общий сдвиг расходов, так и на изменение их структуры и при этом остается единственным методом, позволяющим отделить движение всего региона от событий в отдельном муниципалитете.

Таким образом, выигрыш дало не усложнение статистического теста, а более точное представление о «норме», в роли которой выступает прогноз модели, очищенный от движения страны и региона, тогда как итоговая оценка улавливает и общий сдвиг расходов, и перемены в их структуре.

6.4. Итоговый алгоритм выявления шоков

Алгоритм применяется к каждому новому месяцу t сразу после поступления данных и состоит из следующих шагов.

1. Итоговая прогнозная модель, обученная на месяцах до $t - 1$, строит прогноз $\hat{y}_{i,c,t}$ на один месяц для каждого МО и каждой из шести категорий. Этот прогноз служит ожидаемым значением.
2. Для каждого МО и категории рассчитывается отклонение $d_{i,c,t} = \log\left(\frac{y_{i,c,t}}{\hat{y}_{i,c,t}}\right)$. Оно нормируется внутри группы «категория $\times$ месяц $\times$ уровень расходов МО» и на собственную волатильность МО, так что из него удаляется общий для страны промах прогноза и получается величина $z_{i,c,t}$.
3. Медиана z по МО региона принимается за региональную составляющую $r_{R,c,t}$, а остаток $\tilde{\lambda}_{i,c,t}$ - за местную.
4. Местная составляющая делится на разброс прошлых местных отклонений того же МО. Это дает $\tilde{\lambda}_{i,c,t}$ и исключает постоянные тревоги у хронически нестабильных муниципалитетов.
5. По шести категориям рассчитываются оценка top-k $T_{i,t}$ и расстояние Махаланобиса $M_{i,t}$. Обе переводятся в процентиля, и итоговой оценкой становится $C_{i,t} = \max(F_T, F_M)$.
6. Месяц признается шоком МО, если $C_{i,t}$ входит в верхний 1% МО-месяцев, а следующие 2% получают отметку «внимание». Шоком региона считаются верхние 2% регион-месяцев по региональной оценке.
7. Та же оценка рассчитывается по сумме отклонений за два месяца подряд. Так обнаруживаются медленные сдвиги, которые в каждом отдельном месяце теряются в шуме. Они выдаются отдельным флагом постепенного сдвига.
8. Через месяц после тревоги по доле сохранившегося отклонения определяется тип шока - сдвиг уровня, разовый, нарастающий или провал с отскоком
9. Если в последнем известном месяце у МО был шок, интервал его прогноза расширяется в 1,3 раза (раздел 8), а точечный прогноз не корректируется.

В результате для каждого МО-месяца формируются флаг (шок, «внимание», постепенный сдвиг или региональный шок), тип шока, оценка надежности и отклонения по каждой из шести категорий (results/shocks_v2/shocks.csv).

6.5. Ограничения метода и результаты на 2024 год

Шок величиной 5% не удастся отличить от обычного шума ни одним из рассмотренных методов. Падение одной категории находится заметно хуже общего (29% против 77% при шоке 10%). В МО с низкими расходами на жителя шум выше, поэтому падение всех категорий на 10% там обнаруживается в 52% случаев против 89-93% в МО с высокими расходами.

В 2024 г. было выявлено **242 шока у 184 МО**, 484 отметки «внимание», 143 постепенных сдвига и 11 региональных шоков. Пять из одиннадцати региональных шоков пришлось на январь 2024 г. в Алтае, Тыве, Камчатке и Якутии, где новогодний провал оказался глубже, чем по стране. Поскольку это особенность региональной сезонности, а не событие, такие случаи помечены отдельно.

Большинство шоков МО носят устойчивый характер. 140 из 242 представляют собой сдвиги уровня, и через полгода после них сохраняется 41-52% разрыва с регионом (src/shocks/recovery.py). Среди крупнейших выделяются падения расходов на общепит на 40-65% в районах, похожие на закрытие заведений. У 43 МО за год произошло два и более шоков, и если у муниципалитета уже был шок, следующий случается в 3,4% месяцев против 0,7% у остальных.

Шоки концентрируются в малых МО. В пятой части муниципалитетов с наименьшим населением они приходятся на 2,3% месяцев, а в пятой части с наибольшим - лишь на 0,06%, хотя отклонение уже нормировано на шумность МО. Открытие или закрытие одного магазина или кафе заметно меняет траты на жителя небольшого муниципалитета. Чаще всего шоки встречаются в Тыве (11,7% МО-месяцев), Сахалинской области (7,3%) и ЯНАО (3,9%).

Часть найденных шоков удалось постфактум сопоставить с новостями.

- Торопец, сентябрь 2024 г. (атака беспилотников на арсенал): маркетплейсы -23%, транспорт +22%.

- Долинский район Сахалина, январь 2024 г. (циклон и перебои сообщения): транспорт -26%, общепит -36%, здоровье -30%.
- Паводок в Орске, апрель 2024 г.: отметка «внимание» в апреле и шок в мае.

Вместе с тем большинство крупных шоков новостями не объясняется, а часть из них представляет собой артефакты данных - например, рост расходов на общепит на 9600% при почти нулевой базе. Для контроля качества данных такие сигналы полезны, хотя экономическими событиями они не являются.

Отдельно было проверено, нужно ли сдвигать прогноз после шока. Оказалось, что прогноз после шока почти не смещен. В следующем месяце факт уходит в сторону шока дальше прогноза в среднем (по медиане) лишь на 1,7%, через два месяца - на 0,8%, через три - на 0,4%, а знак ошибки совпадает со знаком шока только в 54% случаев. Ошибка после шока больше обычной из-за шума, а не из-за систематического возврата к прежнему уровню. Поэтому корректировать сам прогноз не нужно, достаточно честно расширить его интервал (раздел 8).

7. Новости

Новостной контур тестировался в обеих задачах, как признаки для прогноза и как объяснение найденных шоков. Главная сложность в том, что статья и расходы описаны в разных единицах: у статьи есть город и дата публикации, у расходов - муниципалитет и месяц.

Он был взят из источника **CC-News** - архива новостных статей, который собирает проект Common Crawl. Использовалась его обработанная версия `ruggsea/infini-news-corpus` на HuggingFace - многоязычный корпус в формате `raguet`. У каждой статьи есть адрес и сайт, дата публикации, заголовок, лид (первый абзац), полный текст, язык и тема по классификатору IPTC. Файлы корпуса разбиты по месяцу, когда статью скачал краулер, а не по месяцу публикации.

Из него были выгружены:

- **месяцы скачивания** с декабря 2022 г. по январь 2025 г. (14 861 файл); статьи затем отобраны по дате публикации за январь 2023 - декабрь 2024 г.;
- **только русскоязычные статьи российских изданий** из заданного списка: федеральные (РИА Новости, ТАСС, Интерфакс, Лента.ру, РБК, Коммерсантъ, Известия, Газета.ру и др.) и крупные региональные сети (URA.RU, Фонтанка, НГС, Е1, 74.ru и др.);
- **только заголовок и лид**, без полного текста.

Итого около **3,9 млн статей 28 изданий**, от 79 до 196 тыс. в месяц.

Далее мы привязали новости к месяцу и муниципалитету следующим образом:

- Месяц определяется по дате публикации.
- Муниципалитет - по названию города. В справочнике СберИндекса у каждого МО указан административный центр («г Орск»). Статья относится к МО, если в заголовке или лиде упомянут его центр в любом падеже (Орск, Орская, в Орске). Если у города и одноименного района один центр, статья относится к более населенному МО.
- Исключили совпадения - названия, которые встречаются в нескольких регионах, совпадают с обычными словами, именами и фамилиями или городами других стран (Владимир, Киров, Мир, Зима, Шахты, Королев), похожие на фамилии названия городов меньше 150 тыс. жителей (на - ов, - ев, - ин), названия-прилагательные и названия короче четырех букв.

После отсева в словаре осталось 663 города. В основной выборке это **629 из 2016 МО**.

7.1. Новостные признаки для прогноза

Далее были выделены две темы, которые могут менять расходы, по словарям ключевых слов.

- 1) ЧС и стихия (паводок, подтопление, эвакуация, природные пожары, ураган, землетрясение, оползень)
- 2) связанные с ЖКХ (отключения, например, нет света, тепла, воды, газа; аварии на ТЭЦ, теплотрас-

сах, подстанциях).

Статья засчитывается муниципалитету, если в ее заголовке или лиде есть и город, и тема. Всего к МО привязано 10122 статьи о ЧС и 3156 об отключениях.

Далее число статей приводится к одному масштабу. Объем новостного корпуса сильно колеблется от месяца к месяцу, от 79 до 196 тыс. статей, потому что отдельные издания то появляются в архиве, то пропадают из него. Если считать статьи напрямую, месяц, в котором в корпус попало больше изданий, выглядел бы как всплеск новостей о городе, хотя на деле ничего не произошло. Поэтому число статей о городе за каждый месяц пересчитывается так, как если бы в корпусе было ровно 100 тыс. статей.

Затем учитывается, что о разных городах пишут с разной частотой. О Новосибирске или Екатеринбурге новости выходят постоянно, а о небольшом городе - редко. Поэтому сам по себе объем статей ничего не говорит о событии, и важно другое - насколько в этом месяце о городе написали больше, чем обычно. Это показывает признак всплеска:

$$s_m = \log \frac{n_m + 1}{\text{med}_{k < m} n_k + 1}$$

где n_m - нормированное число статей о городе на выбранную тему в месяц m , а $\text{med}_{k < m} n_k$ - его обычный уровень, то есть медиана за все предыдущие месяцы. Единица добавлена, чтобы формула работала и для месяцев без статей. Если о городе написали столько же, сколько обычно, признак равен нулю. Если впятеро больше, он равен примерно 1,6. Обычный уровень считается только по прошлым месяцам, чтобы в признак не попадала информация из будущего.

Наконец, нужно решить, какие новости модель видит в момент прогноза. Прогноз на месяц t строится в конце месяца $t - 1$ поэтому модель получает всплески новостей за два предыдущих месяца, $t - 1$ и $t - 2$ отдельно по ЧС и по отключениям. При прогнозе на несколько месяцев вперед используются только новости, вышедшие до момента прогноза. Более поздние в тот момент еще неизвестны.

Чтобы оценить пользу новостей, мы обучили ту же модель с новостными признаками и без них и сравнили обе версии по одному и тому же протоколу проверки (раздел 4).

7.2. Что новости дали прогнозу

На всей панели прогноз на 1 месяц с новостями хуже: MAE выше в среднем по категориям на 1,0-1,3% (для двух версий модели). На 3-12 месяцев изменения составляют от -4% до +9% без устойчивого знака.

В среднем по 2016 МО новостные признаки почти ничего не меняют, потому что событий мало. Поэтому отдельно проверены месяцы сразу после событий: всплеск не меньше 10 статей и в 5 раз выше обычного для ЧС (78 случаев), не меньше 5 статей и в 4 раза выше обычного для отключений (57 случаев). Ошибка измерялась как $|\log(\text{прогноз} / \text{факт})|$ в процентных пунктах, интервал - бутстрапом по МО.

Таблица 9. Ошибка прогноза с новостными признаками и без них

Наблюдения	Прогнозов	Ошибка без новостей, п.п.	Изменение с новостями, п.п. (95% интервал)
Все МО, прогноз на 1 месяц	145 152	7,09	+0,07 (+0,07...+0,08)
1-й месяц после ЧС	276	4,48	-0,05 (-0,18...+0,08)
2-й месяц после ЧС	318	4,31	+0,21 (+0,09...+0,34)
1-й месяц после отключений	264	6,67	-0,16 (-0,33...-0,01)
2-й месяц после отключений	336	6,52	+0,14 (-0,03...+0,31)

Примечание. Версия модели с целью в логарифмах; у версии с целью в рублях картина та же.

Небольшой выигрыш есть только в первый месяц после отключений, и тот на границе шума. Во второй месяц после ЧС новости прогноз ухудшают. Региональные новостные индексы (доля статей о ЧС и отключениях по субъекту) с изменением расходов не связаны: $|r| < 0,07$ на 1 723 регион-месяцах. События локальны, и медиана по региону их гасит.

7.3. Почему новости почти не помогают прогнозу

Первая причина, по всей видимости, в том, что данные агрегированы по месяцам, а большинство событий длится всего несколько дней. Паводок, циклон или отключение влияют на расходы лишь короткое время, и в среднемесечных значениях их эффект размывается.

Вторая причина в том, что новости прошлого месяца приходят слишком поздно, чтобы что-то добавить к прогнозу. Прогноз на месяц t строится в конце месяца $t - 1$, когда расходы за этот месяц уже известны. Допустим, в каком-то городе в прошлом месяце произошло наводнение и траты резко упали. Модель увидит этот провал в самих данных через признак последнего прироста, а новость о наводнении лишь объяснит его причину, не добавив новой информации. Для прогноза же важно, как расходы поведут себя дальше, а это зависит от типа события. После одних событий траты быстро восстанавливаются и даже ненадолго превышают обычный уровень, после других остаются пониженными, а эффект отключений и вовсе исчезает уже к следующему месяцу. В среднем после ЧС в следующем месяце наблюдается лишь слабый отскок «Всех категорий» (+0,6 п.п.). Чтобы научиться различать такие сценарии, модели нужны десятки похожих случаев, а в обучающей выборке крупных событий почти нет.

Третья причина в том, что новости текущего месяца связаны с расходами заметно сильнее, но в прогнозе их использовать нельзя. Например, после всплеска статей об отключениях расходы на Здоровье в том же месяце оказываются ниже на 2 п.п. Однако в момент прогноза новостей этого месяца еще нет, и включить их в признаки значило бы заглянуть в будущее. Такие новости могли бы пригодиться для оценки текущего месяца до публикации данных СберИндекса, но эта задача выходит за рамки нашей постановки.

7.4. Новости в детекторе шоков

Для детектора новости полезнее: им не нужно предсказывать будущее, их задача - объяснить уже найденное отклонение. К каждому крупному шоку подбираются статьи о его МО за месяц шока.

- Шоки, найденные по отклонению от прогноза, совпадают с новостным всплеском в 5,1% случаев. Среди месяцев без шока у тех же городов всплеск бывает в 1,9% случаев, то есть у шоков в 2,7 раза чаще. У детектора по сравнению с регионом (регр) такой связи нет: 1,5% против 1,5%.
- Примеры совпадений: Торопец, сентябрь 2024 г. (атака беспилотников на арсенал): маркетплейсы -23%, транспорт +22%; Долинский район Сахалина, январь 2024 г. (циклон, нарушено автомобильное сообщение): транспорт -26%, общепит -36%; Орск, паводок в апреле 2024 г.: отметка «внимание» в апреле и шок в мае.
- Из 60 крупнейших шоков 2024 г. новостным всплеском объясняются 2, у 8 МО нет города в словаре, для 50 объяснения не нашлось. Большинство шоков - закрытие или открытие отдельных точек и изменения в данных, о которых федеральные издания не пишут.

7.5. Как согласовывать новости с данными СберИндекса

По итогам работы мы пришли к схеме, которую можно рекомендовать для любых задач, где новости сопоставляются с муниципальными данными СберИндекса.

Месяц статьи нужно определять по дате публикации, а не по дате, когда ее скачал краулер. Для прогноза на месяц t допустимо использовать только новости, вышедшие до конца месяца $t - 1$.

Привязывать статью к муниципалитету удобнее всего через справочник СберИндекса, где для каждого МО указаны административный центр, код ОКТМО и регион. Названия, которые нельзя однознач-

но отнести к одному муниципалитету, лучше исключить.

Само число статей мало что говорит о событии, поэтому его нужно нормировать дважды. Сначала на общий объем корпуса за месяц, а затем на обычный уровень упоминаний города. Тогда признак показывает не количество новостей, а всплеск относительно нормы. Обычный уровень при этом считается только по прошлым месяцам, чтобы в признак не попадала информация из будущего.

Пользу новостей стоит оценивать в зависимости от задачи. Для прогноза на 3-12 месяцев они не нужны, а для прогноза на месяц вперед могли бы пригодиться только при оценке текущего месяца с учетом даты события. Для поиска шоков они полезны как объяснение найденного отклонения и как способ отличить реальное событие от изменения в данных.

В итоге новости удастся корректно привязать к муниципалитету и месяцу, и их связь с расходами в том же месяце действительно есть. Однако при месячных данных и прогнозе, который строится в конце прошлого месяца, новости либо запаздывают, потому что эффект события уже виден в самом ряду, либо появляются уже после момента прогноза. Поэтому в итоговый прогноз они не вошли, а при поиске шоков используются для объяснения найденных отклонений.

8. Интервалы прогноза

Чтобы оценить, насколько можно доверять прогнозу конкретного муниципалитета, для каждого прогноза строится 90%-ный предсказательный интервал - диапазон, в который факт должен попасть с вероятностью 90% (`src/forecast/intervals.py`). Его границы задаются 5%- и 95%-ными квантилями прошлых ошибок $\log(\text{факт}/\text{прогноз})$, рассчитанными отдельно для каждой категории, горизонта и группы МО по волатильности (всего пять групп):

$$[\hat{y} \cdot e^{q_{0,05}}, \hat{y} \cdot e^{q_{0,95}}].$$

Если в последнем известном месяце у МО был зафиксирован шок, интервал расширяется в 1,3 раза, поскольку прогноз для таких муниципалитетов остается несмещенным, но его ошибка заметно больше обычной.

Параметры интервалов оценивались на январе-июне 2024 г., а проверялись на июле-декабре. Качество интервала измеряется покрытием - долей фактов, попавших в интервал, - при целевом значении 90%.

Таблица 10. Покрытие и ширина 90%-ных интервалов прогноза

Горизонт	Покрытие	После шока, без расширения	После шока, с расширением	Медианная ширина, % уровня
1 мес.	93%	83%	92%	36%
3 мес.	92%	80%	88%	42%
6 мес.	91%	85%	89%	50%
12 мес.	78%	73%	83%	44%

На горизонтах 1-6 месяцев интервал выполняет свое обещание, обеспечивая покрытие 91-93% при цели 90%, а расширение после шока возвращает покрытие у таких МО к целевому уровню. На горизонте 12 месяцев покрытие ниже цели. При проверке квантили для этого горизонта оценивались по шагам 1-6 единственного прогноза, а проверялись на шагах 7-12, где ошибка больше. Если продлить рост ширины, оцененный по шагам 1-6, покрытие поднимается до 83%. В прогнозе на 2025 г. квантили для шагов 7-12 оценены уже по всем двенадцати шагам 2024 г.

9. Прогноз на тестовой выборке (2025 год)

Для итогового прогноза обе версии модели обучены на всех 24 месяцах (`src/forecast/forecast_2025.py`). Поскольку январь теперь присутствует в обучении, для каждой категории и каждого шага берется та версия, которая точнее прогнозировала 2024 г. на том же горизонте. От правила из подраздела 5.5 такой выбор отличается лишь для Транспорта (версия А на всех шагах) и первого месяца Маркетплейсов.

Для каждого МО построены прогноз на январь-декабрь 2025 г. и 90%-ный интервал. Медиана прогноза по МО относительно декабря 2024 г. составляет для «Всех категорий» -25% в январе и +12,5% к декабрю 2025 г., а для Маркетплейсов -36% в январе и +28% к декабрю. Ширина интервала колеблется от 10-25% уровня у «Всех категорий» и Продовольствия до 45-99% у Общепита и Маркетплейсов.

Данных СберИндекса по муниципалитетам за 2025 г. в открытом доступе нет, однако есть национальный ряд расходов по типам трат, по которому можно проверить прогноз в сумме по всем МО (`src/forecast/check_2025.py`). Для этого прогноз по МО агрегируется с весами, пропорциональными численности населения, и его рост к декабрю 2024 г. сравнивается с ростом национального ряда.

Таблица 11. Расхождение суммарного прогноза по МО с национальным рядом, средняя за 12 месяцев разница, п.п.

Категория	Прогноз 2025 г. против страны	Для сравнения: факт МО против страны в 2024 г.
Все категории	2,3	2,0
Продовольствие	3,1	3,7

Сумма прогноза по МО следует за страной так же близко, как в 2024 г. за ней следовал факт МО, и систематического ухода прогноза в сторону не наблюдается. Это проверка лишь общего уровня. Такой же точности по стране достигает и простой ориентир «рисунок 2024 г. × годовой рост» (2,0 и 2,8 п.п.), а точность по отдельным МО таким способом проверить нельзя. Для остальных категорий национальные ряды не совпадают с категориями СберИндекса по составу (у общепита расхождение факта МО со страной в 2024 г. достигало 13 п.п.), поэтому сравнение по ним неинформативно.

10. Приложение

10.1. Что проверили и не включили

Помимо моделей и методов из разделов 5 и 6, в ходе работы мы проверили еще ряд идей. Они могли бы улучшить прогноз, но в итоговое решение не вошли, потому что не дали устойчивого выигрыша. Эти проверки собраны в трех таблицах. В таблице 12 приведены альтернативные модели и схемы прогноза, в таблице 13 - дополнительные источники данных и признаки, в таблице 14 - способы обработки шоков и выбросов.

В каждой строке указана проверенная идея и ее результат. Все идеи проверялись по тому же способу валидации, что и основные модели (раздел 4). Изменение MAE считается относительно итоговой модели без этой доработки, поэтому минус означает, что ошибка уменьшилась, а плюс - что она выросла. Пометка «в пределах шума» значит, что изменение не превышает разброса, который дает сама модель при переобучении с другим seed.

Таблица 12. Альтернативные модели и схемы прогноза

Идея	Результат
TabPFN-3 вместо CatBoost	MAE выше на 8-10% на 1 мес. и на 40-80% на 6-12 мес.: модель вмещает 8-12 тыс. строк обучения из 20-42 тыс.
TabFM (Google Research)	на трех стартах -17%, +3% и -14% к CatBoost; полный прогон требует GPU, выигрыш не доказан
Прямой прогноз на k месяцев одной моделью (direct multi-step)	на 12 мес. хуже рекурсии во всех категориях
Одна модель на все категории (категория как признак)	MAE выше на 3-69%
Выбор модели под каждую ячейку «категория × горизонт» по прошлым ошибкам	хуже одной модели: среди почти одинаковых вариантов «лучший по прошлому» выбирается почти случайно
Ансамбли, среднее нескольких seed, глубина, регуляризация, MAE-потери, веса по размеру МО	в пределах шума

Таблица 13. Дополнительные данные и признаки

Идея	Результат
Квартальные показатели МО Росстата (розница, общепит, зарплата, занятость)	в пределах шума
Помесячные ИПЦ и зарплаты регионов (Росстат, ЕМИСС)	помогают только «Всем категориям» на 3-12 мес. (MAE ниже на 4-15%), остальным вредят (Маркетплейсы - до +46%)
Помесячный оборот общепита по регионам (Росстат)	с данными СберИндекса не связан даже в тот же месяц (корреляция 0,02)
Новости о ЧС и отключениях по городу (СС-News, 3,9 млн статей)	MAE выше на 0,7-1,4%
Признаки «МО относительно своего региона»	MAE от -8% до +8%, чаще выше
Рамадан (даты поста × доля мусульман)	помогает общепиту Северного Кавказа в апреле 2024 г. (-27...-52%), но эти МО есть только среди неполных рядов
Обучение на 174 неполных рядах	на полных МО не помогает
Прогноз на день вместо месяца (29 февраля 2024 г.)	февраль исправляется, март портится на столько же
Профиль панели, смешанный с национальным	MAE выше на 7-22%
Большой вес свежим месяцам обучения	MAE от 0 до +7%
Масштабирование прогнозов МО под прогноз региона или страны	хуже везде
Структура трат МО и тип сезонности МО (k-means)	на 1 мес. от -3% до +2%, на 3-12 мес. MAE выше до 20%
Приросты других категорий того же МО за прошлый месяц	Маркетплейсы -9,5% на 1 мес. (только январь-июнь), на 6-12 мес. +25...+29%
Ночевки в гостиницах на жителя (БДП-МО, 2022 г.)	MAE -0,4...-1,4%, знак зависит от seed
Собственный тренд МО (наклон за 6 и 12 месяцев)	MAE от -2,5% до +9,8%
МО как категориальный признак	Маркетплейсы -1...-12% на всех горизонтах и трех seed, остальные категории на 6-12 мес. до +11%; правила, выделяющего Маркетплейсы без взгляда на тест, не нашлось
Сезонный профиль панели как признак версии Б	на 1 мес. MAE ниже на 4-19%, но только в январе-июне 2024 г.; на 6-12 мес. выше у Маркетплейсов и Здоровья до +19%; Транспорту помогает на всех горизонтах (-3...-16%)

Таблица 14. Обработка шоков и выбросов

Идея	Результат
Обрезка крайних приростов в обучении (1% и 5% по месяцу, winsorization)	MAE выше на 0,3-9%
Замена одиночных выбросов средним соседей	MAE от -0,5% до +3,6%
Исключение из обучения скачков больше чем в 2 раза за месяц	в пределах шума: -0,1...+0,8% в среднем по трем seed
Поправка прогноза после шока	коэффициент, подобранный на первой половине 2024 г., на второй не работает
Перенос истории до устойчивого сдвига уровня на новый уровень	Общепит +4...+23%, Здоровье +3...+5%, Транспорт до +9%; у Маркетплейсов -1...-8%, но только в первой половине года
Сдвиг уровня (величина, давность) как признак	MAE от -0,3% до +4,5%
Просроченная задолженность по зарплате в МО (БДПМО) как фактор шоков	доля шоков у МО с долгом 1,2%, без долга 1,3% - связи нет

10.2. Ограничения решения

Прогноз на 12 месяцев оценен по единственной точке старта, и в его обучении отсутствует январь; при двух и более годах истории, как в прогнозе на 2025 г., панельный профиль уже знает январь, и главный источник ошибки уходит.

Правило выбора версии из подраздела 5.5 назначает Транспорт версии Б, хотя профиль ему помогает: по одному году истории этого не видно.

В малых и удаленных МО ошибка прогноза в 2-4 раза выше, а шоки обнаруживаются вдвое хуже, и при текущих данных это похоже на неустраняемый шум.

Метод выявления шоков не знает их причин, и новостями объясняются лишь единичные случаи.

Наконец, в данных целиком отсутствуют восемь регионов: Краснодарский край, Белгородская, Брянская, Воронежская, Курская и Ростовская области, Крым и Севастополь.